

# Evaluation and Prediction of TikTok KOL Effectiveness in the Cosmetics Sector: A Survey and Modeling Study

Ung Hoàng Long<sup>1,2</sup>, Hà Xuân Hoàng<sup>1,3</sup>, and Đỗ Trọng Hợp<sup>1,4</sup>

<sup>1</sup>University of Information Technology, Ho Chi Minh City, Vietnam  
{<sup>2</sup>23520892, <sup>3</sup>23520516}@gm.uit.edu.vn, <sup>4</sup>hopdt@uit.edu.vn  
<https://student.uit.edu.vn/>

**Abstract.** Trong kỷ nguyên số, TikTok đang nổi lên như một nền tảng tiếp thị đầy tiềm năng, đặc biệt trong ngành mỹ phẩm. Tuy nhiên, việc lựa chọn đúng KOL (Key Opinion Leader) để hợp tác vẫn là một thách thức lớn đối với doanh nghiệp, khi hiệu quả quảng bá không chỉ phụ thuộc vào độ nổi tiếng mà còn nằm ở sự phù hợp về nội dung, thời điểm và mức độ tương tác thực tế. Nghiên cứu này tiếp cận vấn đề từ góc nhìn định lượng, thông qua việc thu thập và phân tích dữ liệu từ 86 KOL TikTok chuyên về mỹ phẩm với hơn 25.000 bài đăng, trải dài từ tháng 1/2024 đến tháng 5/2025. Các giả thuyết về mối liên hệ giữa đặc điểm của KOL và hiệu quả tương tác được kiểm định bằng các phương pháp thống kê phi tham số, trước khi xây dựng mô hình học máy nhằm dự đoán tỷ lệ tương tác trên các bài PR trong tương lai. Kết quả bước đầu cho thấy một số yếu tố như nhãn “commerceUser”, “ttSeller” không mang ý nghĩa thống kê rõ ràng, trong khi lịch sử tương tác, định dạng nội dung và thời gian đăng bài lại thể hiện vai trò đáng kể. Dẫu vậy, hiệu suất dự đoán từ các mô hình vẫn còn hạn chế, phản ánh rõ thách thức trong việc mô hình hóa hành vi người dùng mạng xã hội. Những phát hiện này không chỉ cung cấp cơ sở thực nghiệm cho doanh nghiệp trong việc lựa chọn KOL mà còn gợi mở nhiều hướng nghiên cứu sâu hơn về mô hình hóa tương tác người dùng trong môi trường dữ liệu động và đa chiều.

**Keywords:** KOL · TikTok · Influencer Marketing · Cosmetics · Machine Learning · Effectiveness Evaluation

## 1 Introduction

Trong kỷ nguyên số, sự bùng nổ của mạng xã hội đã định hình lại chiến lược tiếp thị của các doanh nghiệp, đặc biệt trong ngành mỹ phẩm. Key Opinion Leaders (KOLs) đang nổi lên như một kênh truyền thông then chốt, không chỉ tạo ra nội dung hấp dẫn mà còn định hình xu hướng và ảnh hưởng đến hành vi tiêu dùng. Tuy nhiên, việc lựa chọn KOL phù hợp cho các chiến dịch quảng bá vẫn là một thách thức lớn. Thị trường KOL mở rộng nhanh chóng, đa dạng về quy mô và hình thức, dẫn đến sự thiếu hụt các phương pháp đáng tin cậy để

dự đoán hiệu quả thực sự. Quyết định hợp tác thường dựa vào các chỉ số bề nổi (như số lượt theo dõi) hoặc cảm quan chủ quan, bỏ qua các chỉ báo định lượng giá trị về hành vi tương tác hoặc yếu tố ngữ cảnh.

## 2 Related Work

Lĩnh vực KOL và influencer marketing đã thu hút sự quan tâm đáng kể. Các nghiên cứu ban đầu tập trung vào mối quan hệ giữa sự tin tưởng vào KOL và thái độ người tiêu dùng, với các công trình chỉ ra tính chân thực và mức độ phù hợp giữa KOL với thương hiệu là yếu tố then chốt đến hiệu quả chiến dịch. Trong ngành mỹ phẩm, influencer marketing đóng vai trò đặc biệt quan trọng, được ghi nhận giúp tăng tỷ lệ chuyển đổi và mức độ ghi nhớ thương hiệu, với tỷ lệ ROI trung bình là 4.3 lần. Dữ liệu thực tiễn cũng cho thấy TikTok có tỷ lệ tương tác trung bình cao hơn đáng kể so với các nền tảng khác. Tuy nhiên, phần lớn các nghiên cứu hiện tại vẫn sử dụng phương pháp định tính hoặc thống kê mô tả đơn giản, chưa khai thác triệt để dữ liệu hành vi thực tế hoặc đưa ra công cụ dự đoán định lượng. Các chỉ số giá trị như tỷ lệ bình luận thực sự, tốc độ lan truyền, hoặc mức độ nhất quán của nội dung thường chưa được khai thác. Ngoài ra, phần lớn các công trình tập trung vào Instagram hoặc YouTube, trong khi TikTok – với đặc thù nội dung ngắn, định dạng đa phương tiện và thuật toán phân phối cá nhân hóa cao – vẫn chưa được khai thác đầy đủ từ góc độ định lượng. Khoảng trống nghiên cứu rõ ràng là thiếu một mô hình định lượng có khả năng dự đoán hiệu quả thực sự của KOL TikTok dựa trên hành vi tương tác trong quá khứ. Việc xây dựng mô hình như vậy không chỉ cung cấp cơ sở dữ liệu vững chắc cho doanh nghiệp trong quyết định hợp tác KOL, mà còn mở ra hướng nghiên cứu mới trong việc đo lường hiệu quả truyền thông trên nền tảng xã hội động như TikTok.

## 3 Methodology

### 3.1 Research Design




Fig. 1: Quy trình thực hiện dự án nghiên cứu

Các phần tiếp theo của bài báo sẽ đi sâu vào chi tiết từng bước trong quy trình này, bao gồm chiến lược thu thập và xây dựng dữ liệu (Data Collection and Data Engineering), phương pháp kiểm định giả thuyết (Hypothesis Testing), và quy trình xây dựng mô hình học máy (Machine Learning Methodology).

### 3.2 KOL Selection

Nghiên cứu tập trung vào 86 KOL hoạt động trong lĩnh vực mỹ phẩm trên TikTok. Các KOL này được xác định thông qua việc tham khảo các trang thống kê và báo cáo uy tín về thị trường KOL, kết hợp với khảo sát từ những người dùng nữ quan tâm đến nội dung mỹ phẩm trên TikTok. Quá trình lựa chọn này nhằm đảm bảo tính chuyên biệt và phù hợp với trọng tâm nghiên cứu, dù chỉ giới hạn trong một lĩnh vực cụ thể.

### 3.3 Data Collection and Feature Engineering




Fig. 2: Quy trình xử lý dữ liệu

Trong nghiên cứu này, chúng tôi đã xây dựng một bộ dữ liệu toàn diện nhằm phân tích hành vi và hiệu suất của các nhà sáng tạo nội dung chính (Key Opinion Leaders - KOLs) trên nền tảng TikTok. Quy trình thu thập và xử lý dữ liệu được thực hiện một cách tỉ mỉ, bao gồm thu thập dữ liệu thô, thiết kế các đặc trưng kỹ thuật tiên tiến, và tổng hợp dữ liệu theo cấu trúc đa cấp độ.

**Data Acquisition and Initial Dataset Overview** Dữ liệu chính của nghiên cứu được thu thập thông qua API Crawler của nền tảng Apify, kết nối trực tiếp với API công khai của TikTok. Dữ liệu được thu thập trong khoảng thời gian 17 tháng, từ ngày 01 tháng 01 năm 2024 đến ngày 31 tháng 05 năm 2025. Bộ dữ liệu sơ khởi bao gồm thông tin chi tiết về 86 KOLs hoạt động trong lĩnh vực mỹ phẩm. Từ các tài khoản này, chúng tôi đã ghi nhận tổng cộng hơn 25.000 bài đăng (posts), tương đương với trung bình khoảng 350 bài đăng cho mỗi KOL. Mỗi bài đăng này được xem là một đơn vị quan sát độc lập tại cấp độ cơ sở (Level 1), được gọi là "dữ liệu bài đăng thô".

**Level 1: Raw Post Data and Initial Attributes** Tại cấp độ này, mỗi mẫu quan sát (tức là mỗi bài đăng) được mô tả bởi hơn 20 thuộc tính cơ bản, cung cấp cái nhìn toàn diện về nội dung bài đăng:

- **Dữ liệu bài đăng:** Bao gồm nội dung văn bản (*caption*), thời gian đăng tải (*createTime*), định danh và tên của nhạc nền sử dụng (*musicId*, *musicName*), độ dài của video (*duration*), khung giờ đăng tải, danh sách các hashtag kèm theo, và các dữ liệu về phụ đề, video của bài đăng.
- **Chỉ số tương tác:** Các chỉ số định lượng về hiệu suất bài đăng như lượt xem (*playCount*), lượt thích (*diggCount*), lượt chia sẻ (*shareCount*), lượt bình luận (*commentCount*), và lượt lưu bài viết (*collectCount*) được thu thập đầy đủ.
- **Nhãn kỹ thuật:** Ngoài ra, mỗi bài đăng còn được gắn kèm các nhãn phân loại tự động như bài đăng quảng cáo/PR (*isAD*), bài trình chiếu ảnh (*isSlideshow*), tài khoản có tích hợp chức năng thương mại (*commerceUser*), và tài khoản được hỗ trợ bán hàng bởi TikTok (*ttSeller*).

**Advanced Feature Engineering and External Data Integration** Để tăng cường khả năng biểu diễn của dữ liệu và nắm bắt sâu hơn các sắc thái hành vi, nhóm nghiên cứu đã chủ động thiết kế và xây dựng một loạt các đặc trưng cao cấp (engineered features):

- **Đặc trưng *is\_trending*:** Một thuộc tính nhị phân được tạo ra bằng cách sử dụng mô hình ngôn ngữ lớn (Large Language Model - LLM), cụ thể là Gemini, để phân tích nội dung *caption*. Mục tiêu là xác định xem bài đăng có chứa yếu tố xu hướng thịnh hành tại thời điểm đó hay không. Việc gán nhãn được thực hiện bán tự động dựa trên đầu ra của mô hình LLM.
- **Đặc trưng *e\_outlier\_pr*:** Phản ánh số lượng bài đăng PR có hiệu suất tương tác vượt trội (outlier) trong giai đoạn đầu vào. Ngưỡng outlier được xác định bằng phương pháp thống kê IQR (Interquartile Range), theo đó các bài đăng có tỷ lệ tương tác cao hơn  $Q3 + 1.5 \times IQR$  được coi là ngoại lệ tích cực.
- **Các đặc trưng kỹ thuật khác:** Bao gồm độ dài của *caption* (*caption\_length*), số lượng biểu tượng cảm xúc (*num\_emojis*), số lượng hashtag (*num\_hashtags*), tần suất bài PR được đăng vào cuối tuần (*is\_weekend\_pr*), và mức độ đa dạng trong việc sử dụng nhạc nền (*music\_uniqueness*).

Ngoài ra, nhằm mở rộng phạm vi biểu diễn về mặt hành vi KOL, chúng tôi đã tích hợp thêm dữ liệu ngoại vi từ nền tảng Social Blade thông qua công cụ Selenium. Nguồn dữ liệu này cung cấp lịch sử tăng trưởng người theo dõi của mỗi KOL theo thời gian, từ đó cho phép trích xuất các đặc trưng động như tốc độ tăng trưởng người theo dõi trong giai đoạn đầu vào (*follower\_change\_in\_input\_window*).

## Level 2: KOL-level Aggregated Data and Target Variable Definition

Sau khi hoàn thiện dữ liệu bài đăng ở cấp độ 1, toàn bộ thông tin được tổng hợp lên cấp độ thứ hai (Level 2), đại diện cho dữ liệu theo từng KOL trong các khung thời gian trượt (sliding windows). Việc tổng hợp này nhằm mục đích chuyển đổi các quan sát chi tiết ở cấp độ bài đăng thành các đặc trưng cấp độ KOL, phản ánh hành vi và hiệu suất tổng thể của KOL trong các khoảng thời gian nhất định.

Table 1: Cấu trúc Khung thời gian Trượt cho Dữ liệu Cấp độ 2

| Số mẫu cho mỗi KOL | Input (6 tháng) | Output (3 tháng) |
|--------------------|-----------------|------------------|
| 1                  | 1-6/2024        | 8-10/2024        |
| 2                  | 2-7/2024        | 9-11/2024        |
| 3                  | 3-8/2024        | 10-12/2024       |
| 4                  | 4-9/2024        | 11/2024 - 1/2025 |
| 5                  | 5-10/2024       | 12/2024 - 2/2025 |
| 6                  | 6-11/2024       | 1-3/2025         |
| 7                  | 7-12/2024       | 2-4/2025         |
| 8                  | 8/2024 - 1/2025 | 3-5/2025         |

Cấu trúc mỗi mẫu dữ liệu tại Level 2 được thiết kế theo mô hình khung thời gian trượt ba phần (Table 1), nhằm hỗ trợ mục tiêu dự đoán và tránh rò rỉ thông tin (data leakage) giữa các giai đoạn:

- **Cửa sổ Đầu vào (Input Window):** Kéo dài sáu tháng (ví dụ: tháng 1-6/2024), chứa dữ liệu được sử dụng để xây dựng các đặc trưng dự đoán.
- **Cửa sổ Đệm (Buffer Window):** Kéo dài một tháng, được đặt giữa cửa sổ đầu vào và đầu ra. Vai trò chính của cửa sổ này là tạo khoảng đệm thời gian, đảm bảo không có thông tin từ cửa sổ đầu ra bị rò rỉ vào việc tính toán đặc trưng, từ đó tăng tính tin cậy của mô hình dự đoán.
- **Cửa sổ Đầu ra (Output Window):** Kéo dài ba tháng (ví dụ: tháng 8-10/2024, tương ứng với Input 1-6/2024 và Buffer tháng 7/2024). Đây là khoảng thời gian mà biến mục tiêu được tính toán, phản ánh hiệu suất của KOL sau giai đoạn đầu vào.

Với thiết kế khung thời gian trượt này, mỗi KOL có thể đóng góp từ một đến tám mẫu quan sát ở cấp độ 2, tùy thuộc vào độ dài lịch sử hoạt động và dữ liệu sẵn có, như minh họa trong Table 1.

Các đặc trưng được xây dựng cho mỗi mẫu Level 2 dựa trên dữ liệu tổng hợp từ cửa sổ đầu vào. Chúng được phân loại thành ba nhóm chính:

- **Đặc trưng Thông Tổng hợp:** Bao gồm tổng số lượng các thuộc tính cơ bản từ Level 1, chẳng hạn như tổng số bài đăng, tổng số lượt xem, tổng số bài đăng PR có lượng tương tác đột biến (outlier), và tổng số bài hát/âm thanh độc nhất (unique music) được sử dụng trong giai đoạn đầu vào.
- **Đặc trưng Tỷ lệ:** Được suy ra từ các đặc trưng thô để phản ánh tỷ trọng và mối quan hệ giữa các yếu tố. Ví dụ, tỷ lệ bài PR trên tổng số bài đăng, tỷ lệ bài PR được đăng vào cuối tuần, tỷ lệ *caption* có yếu tố xu hướng, và tỷ lệ bài PR có tương tác vượt ngưỡng.
- **Đặc trưng Kết hợp:** Kết hợp các thuộc tính khác nhau để tạo ra thông tin phức tạp hơn, ví dụ như tỷ lệ bài PR vừa là slideshow vừa là trending, hoặc mật độ hashtag trung bình trên *caption* của các bài PR.

Biến mục tiêu cuối cùng trong mô hình học máy được ký hiệu là *EngagementRateOnPRPost\_target*. Biến này được tính bằng tỷ lệ tương tác trung bình

trên mỗi lượt xem đối với các bài đăng PR trong ba tháng thuộc giai đoạn đầu ra, theo công thức sau:

$$\text{EngagementRateOnPRPost\_target} = \frac{\sum(\text{Digg Count} + \text{Share Count} + \text{Collect Count} + \text{Comment Count})}{\sum \text{Play Count}} \quad (\text{trong giai đoạn Output})$$

Đây là chỉ số định lượng chính nhằm đánh giá hiệu quả tương tác thực tế của KOL đối với các bài đăng PR trong từng giai đoạn nghiên cứu, không những cung cấp một thước đo toàn diện về mức độ gắn kết của khán giả mà còn giúp không thiên vị cho những KOL có lượng follower lớn.

**Data Splitting for Research Objectives** Cuối cùng, bộ dữ liệu đã được xử lý và phân chia phục vụ hai mục tiêu nghiên cứu chính. Một phần của dữ liệu Level 2 được sử dụng để kiểm định các giả thuyết thống kê phi tham số, nhằm phát hiện các yếu tố ảnh hưởng đáng kể đến hiệu suất tương tác của KOL. Song song đó, toàn bộ dữ liệu Level 2 được dùng để huấn luyện và đánh giá hiệu năng của các mô hình học máy hồi quy, với mục tiêu dự đoán biến *EngagementRateOnPRPost\_target*.

### 3.4 Hypothesis Testing

Để phục vụ quá trình kiểm định giả thuyết thống kê, dữ liệu từ Level 2 đã được trích xuất theo một khung thời gian cụ thể nhằm phản ánh các giai đoạn hoạt động và hiệu suất của KOL:

- **Cửa sổ Dữ liệu Đặc trưng (Input Window):** Dữ liệu được thu thập từ tháng 08/2024 đến tháng 01/2025. Giai đoạn này đại diện cho khoảng thời gian thu thập các đặc điểm hành vi và thông tin nền tảng của các KOL.
- **Cửa sổ Dữ liệu Kết quả (Output Window):** Dữ liệu từ tháng 03/2025 đến tháng 05/2025, tập trung vào việc đo lường hiệu quả hoạt động, cụ thể là tỷ lệ tương tác của các KOL trong 3 tháng sau giai đoạn đầu vào.

Việc lựa chọn khung thời gian này, ưu tiên dữ liệu gần nhất, là phù hợp với bối cảnh nghiên cứu hiện tại. Trong môi trường biến động nhanh về nội dung như TikTok, việc nắm bắt xu hướng và hành vi mới nhất của KOLs là yếu tố then chốt để đảm bảo tính thời sự và độ chính xác khi dự đoán hiệu suất tương lai. Điều này giúp các phân tích thống kê phản ánh chân thực hơn thực trạng và động lực tương tác trên nền tảng.

**Vai trò của Kiểm định Giả thuyết đối với Doanh nghiệp** Đối với doanh nghiệp, các kết quả từ kiểm định giả thuyết cung cấp cơ sở định lượng vững chắc để tối ưu hóa chiến lược hợp tác với KOL và nâng cao hiệu quả tiếp thị. Cụ thể, việc xác định các yếu tố có ý nghĩa thống kê (như lịch sử tương tác, định dạng nội dung, thời gian đăng bài) giúp doanh nghiệp hiểu rõ mối quan hệ nhân quả

giữa đặc điểm của KOL và hiệu quả tương tác. Điều này cho phép ra quyết định chiến lược dựa trên giá trị thực tiễn thay vì chỉ phụ thuộc vào các chỉ số bề nổi hoặc cảm quan chủ quan, từ đó tối ưu hóa chi phí và hiệu quả quảng bá. Ví dụ, kết quả kiểm định có thể hướng dẫn doanh nghiệp lựa chọn KOL dựa trên các yếu tố đã được chứng minh là có tác động tích cực đến tỷ lệ tương tác, hoặc điều chỉnh chiến lược nội dung và thời gian đăng bài để phù hợp với xu hướng hiện tại.

**Vai trò của Kiểm định Giả thuyết đối với Mô hình Dự đoán** Trong khuôn khổ xây dựng mô hình dự đoán, kiểm định giả thuyết đóng vai trò then chốt trong việc tinh chỉnh và tối ưu hóa dữ liệu đầu vào. Bằng cách phát hiện các yếu tố có ý nghĩa thống kê ảnh hưởng đến hiệu suất tương tác của KOL, quá trình này cho phép phân nhóm KOL dựa trên đặc điểm và mức độ ảnh hưởng của họ. Điều này hỗ trợ việc tập trung tài nguyên huấn luyện vào các nhóm KOL có đặc điểm tương đồng và phản ứng rõ rệt với các yếu tố được xác định, giúp giảm nhiễu và tăng độ chính xác cho quá trình huấn luyện mô hình trên các tập con quan trọng. Hơn nữa, việc tập trung vào các KOL và đặc trưng đã được xác nhận là phù hợp với xu hướng hiện tại đảm bảo mô hình dự báo chính xác hơn tỷ lệ tương tác tương lai, dựa trên mối quan hệ nhân quả giữa hành vi quá khứ và hiệu quả sau này. Cuối cùng, kết quả kiểm định giả thuyết cung cấp cơ sở vững chắc cho các quyết định chiến lược về cập nhật mô hình, cho phép triển khai các phương pháp linh hoạt như cập nhật bằng mini-batch online learning khi xu hướng thị trường thay đổi nhẹ, hoặc huấn luyện lại (retrain) hoàn toàn mô hình khi xuất hiện những xu hướng mới đáng kể (như nền tảng xã hội mới hoặc sự thay đổi hành vi khán giả).

**Giới thiệu về các phương pháp kiểm định thống kê** Khi các doanh nghiệp ngày càng phụ thuộc vào dữ liệu để đưa ra quyết định chiến lược, việc hiểu rõ các phương pháp kiểm định giả thuyết trở nên quan trọng hơn bao giờ hết. Trong bộ công cụ thống kê, kiểm định t-test và ANOVA là hai phương pháp tham số nổi bật, đóng vai trò cốt lõi trong việc phân tích và so sánh dữ liệu.

- **Kiểm định t-test - Phương pháp so sánh trung bình hai nhóm:** Kiểm định t-test là một phương pháp thống kê dùng để so sánh trung bình của hai nhóm, nhằm xác định xem có sự khác biệt có ý nghĩa thống kê giữa chúng hay không. Phương pháp này bao gồm ba loại chính: Independent t-test (so sánh hai nhóm độc lập), Paired t-test (so sánh cặp quan sát từ cùng một nhóm), và One-sample t-test (so sánh trung bình một nhóm với một giá trị cố định). Kiểm định này yêu cầu dữ liệu tuân theo phân phối chuẩn, quan sát độc lập, và phương sai bằng nhau giữa các nhóm, với công thức cơ bản được biểu diễn qua chỉ số :

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- **Kiểm định ANOVA - Phân tích sự khác biệt giữa nhiều nhóm:** Đây là phương pháp mở rộng khả năng so sánh, cho phép phân tích sự khác biệt giữa trung bình của ba nhóm hoặc nhiều nhóm hơn. Phương pháp này dựa trên việc so sánh phương sai giữa các nhóm ( $MS_{between}$ ) và phương sai trong mỗi nhóm ( $MS_{within}$ ), sử dụng thống kê  $F$  để đánh giá ý nghĩa thống kê. Công thức được biểu diễn như sau:

$$F = \frac{MS_{between}}{MS_{within}}$$

ANOVA yêu cầu dữ liệu tuân theo phân phối chuẩn, phương sai đồng nhất giữa các nhóm, và quan sát độc lập. Phương pháp này thường được áp dụng trong các nghiên cứu so sánh hiệu quả của nhiều yếu tố cùng lúc, chẳng hạn như đánh giá tác động của các chiến lược tiếp thị khác nhau.

Cả hai phương pháp đều là nền tảng quan trọng trong việc kiểm định giả thuyết, giúp doanh nghiệp và nhà nghiên cứu đưa ra kết luận khoa học dựa trên dữ liệu, đặc biệt trong bối cảnh phân tích hiệu quả hoạt động của các KOL như hiện nay.

**Các phương pháp kiểm định thay thế** Khi dữ liệu không tuân theo phân phối chuẩn, việc áp dụng các phương pháp kiểm định thông thường như t-test hoặc ANOVA truyền thống có thể không còn phù hợp. Dưới đây là các phương pháp thay thế hiệu quả để xử lý tình huống này, cùng với cách đo lường mức độ khác biệt giữa các nhóm.

- **Kiểm định Mann-Whitney U - Thay thế t-test:** Là một phương pháp thống kê không tham số (non-parametric test) được thiết kế để so sánh sự khác biệt giữa hai nhóm độc lập mà không yêu cầu giả định về phân phối chuẩn, thay vào đó tập trung vào thứ tự (rank) của các giá trị thay vì trung bình hoặc phương sai, giúp phù hợp với cả dữ liệu định tính và định lượng trong các nghiên cứu thực tế, mang lại độ tin cậy cao. Quy trình thực hiện bao gồm việc thay thế t-test bằng Mann-Whitney U để đánh giá sự khác biệt giữa hai nhóm và sử dụng phương pháp xếp hạng để đảm bảo kết quả chính xác, với công thức được biểu diễn qua :

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2}$$

$$U_2 = R_2 - \frac{n_2(n_2 + 1)}{2}$$

- **Kiểm định Kruskal-Wallis - Thay thế ANOVA:** Kiểm định Kruskal-Wallis được phát triển như một phương pháp không tham số mở rộng từ Mann-Whitney U, cho phép so sánh sự khác biệt giữa ba nhóm hoặc nhiều nhóm hơn khi dữ liệu không tuân theo phân phối chuẩn, đặc biệt hiệu quả trong việc phân tích đa nhóm nhờ khả năng xử lý dữ liệu có phân bố không đồng nhất hoặc không đối xứng bằng cách dựa vào xếp hạng thay vì giả định



về phương sai hay trung bình. Quy trình thực hiện bao gồm việc gộp tất cả dữ liệu từ các nhóm, xếp hạng chúng theo thứ tự tăng dần, và sử dụng thống kê (H)

$$H = \frac{12}{N(N+1)} \sum \frac{R_i^2}{n_i} - 3(N+1)$$

để đánh giá sự khác biệt với độ tin cậy cao, đặc biệt khi dữ liệu không đáp ứng các giả định của ANOVA truyền thống. Những phương pháp này không chỉ hỗ trợ phân tích hiệu quả hoạt động của KOL mà còn mở ra cơ hội tối ưu hóa mô hình dự đoán trong môi trường tiếp thị số đầy biến động.

**Đo lường mức độ khác biệt giữa hai nhóm** Khi các doanh nghiệp ngày càng dựa vào phân tích dữ liệu để đánh giá hiệu quả chiến lược, đặc biệt trong việc so sánh hiệu suất giữa các nhóm (KOL), việc hiểu rõ mức độ khác biệt thực tế giữa các nhóm trở nên thiết yếu hơn bao giờ hết, vượt xa các kết luận dựa chỉ trên ý nghĩa thống kê. Đây chính là nơi Effect Size (kích thước hiệu ứng) đóng vai trò quan trọng, là một chỉ số thống kê được sử dụng để đo lường mức độ khác biệt thực tế giữa hai nhóm, không chỉ dừng lại ở việc xác định liệu sự khác biệt có ý nghĩa hay không. Bằng cách định lượng quy mô của hiệu ứng, Effect Size cung cấp cái nhìn sâu sắc về tầm quan trọng thực tiễn của kết quả, chẳng hạn như sự khác biệt trong tỷ lệ tương tác giữa hai nhóm KOL, với công thức phổ biến được biểu diễn qua

$$d = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}}}$$

Theo thang đo của Cohen (1988), ( $d \approx 0.1$ ) chỉ ra hiệu ứng nhỏ, ( $d \approx 0.3$ ) là hiệu ứng trung bình, và ( $d \approx 0.5$ ) là hiệu ứng lớn, giúp doanh nghiệp đưa ra quyết định chiến lược dựa trên giá trị thực tiễn thay vì chỉ phụ thuộc vào p-value. Sau khi xác định mức độ khác biệt giữa hai nhóm, để biết nhóm nào có trung bình cao hơn, ta so sánh  $(\bar{X}_1)(GroupOne) vs (\bar{X}_2)(GroupTwo)$ .

### Các kiểm định giả thuyết đã thực hiện

- **Giả thuyết 1 và 2: Đánh giá ảnh hưởng của các thuộc tính tài khoản thương mại (commerceUser và ttSeller) đến hiệu quả tương tác** Hai giả thuyết được kiểm định nhằm xác định xem liệu các đặc điểm tài khoản mang tính thương mại như `commerceUser` và `ttSeller` có ảnh hưởng đáng kể đến tỷ lệ tương tác 3 tháng sau của các bài đăng PR hay không. Trong cả hai trường hợp, giả thuyết  $H_0$  đều cho rằng không có sự khác biệt về tỷ lệ tương tác giữa hai nhóm (True/False), trong khi  $H_1$  cho rằng có sự khác biệt. Sử dụng kiểm định Mann-Whitney U do dữ liệu không tuân theo phân phối chuẩn và phương sai không đồng đều, kết quả cho thấy p-value lần lượt là 0.4427 đối với `commerceUser` và 0.7147 đối với `ttSeller` — đều cao hơn ngưỡng ý nghĩa 0.05. Do đó, không có đủ bằng chứng để bác bỏ  $H_0$

trong cả hai giả thuyết. Điều này cho thấy rằng các thuộc tính thương mại trên tài khoản chưa đủ để dự đoán hiệu quả tương tác của KOL. Từ góc độ chiến lược, doanh nghiệp nên tránh việc ưu tiên phân bổ ngân sách truyền thông dựa vào nhân “tài khoản thương mại” (seller/commercial account), mà cần tập trung nhiều hơn vào các yếu tố có tác động rõ ràng như chất lượng nội dung, mức độ tương tác lịch sử, và tần suất hoạt động. Đồng thời, cũng cần tiếp tục thu thập thêm dữ liệu để xác nhận kết luận này trong các nhóm ngành hoặc bối cảnh khác nhau, vì khả năng các nhân như ttSeller không phản ánh chính xác vai trò và mức độ ảnh hưởng thực tế của KOL trong việc thúc đẩy tương tác.

- **Giả thuyết 3 và 4: Đánh giá tác động của mức độ tương tác ban đầu và hoạt động đăng bài dạng SlideShow (không phải bài PR) đến hiệu quả tương tác sau 3 tháng** Hai giả thuyết được thiết lập nhằm kiểm định xem các yếu tố liên quan đến lịch sử hoạt động nội dung của KOL – bao gồm mức độ tương tác ban đầu (`pr_engagement_rate_input`) và số lượng bài đăng không phải PR dạng SlideShow (`isSlideshow_nonpr`) – có ảnh hưởng đến hiệu quả tương tác trên các bài PR trong 3 tháng tiếp theo hay không. Kết quả kiểm định ở giả thuyết 3 cho thấy  $p\text{-value} = 0.015$  (nhỏ hơn 0.05), cho phép bác bỏ  $H_0$  và khẳng định có sự khác biệt có ý nghĩa thống kê giữa hai nhóm KOL có mức tương tác ban đầu cao ( $\geq 0.02$ ) và thấp ( $< 0.02$ ). Điều này cho thấy rằng các KOL có nền tảng tương tác mạnh từ trước có xu hướng duy trì hiệu suất tương tác tốt hơn trong dài hạn. Trong khi đó, giả thuyết 4 kiểm định ảnh hưởng của việc đăng nhiều bài không phải PR dạng SlideShow đến hiệu quả tương tác. Kết quả kiểm định Mann-Whitney U cũng cho thấy  $p\text{-value} = 0.0275$  (nhỏ hơn 0.05), cho phép bác bỏ  $H_0$ , tuy nhiên mức độ ảnh hưởng chỉ ở mức nhỏ ( $R = 0.27$ ), phản ánh rằng giá trị thực tiễn của yếu tố này là hạn chế. Từ hai giả thuyết này, có thể rút ra rằng doanh nghiệp nên ưu tiên hợp tác với các KOL đã có nền tảng tương tác tốt, vì đây là yếu tố có khả năng dự báo hiệu quả chiến dịch về lâu dài. Ngược lại, việc chỉ tăng số lượng bài đăng thường (non-PR slideshow) không đảm bảo sẽ cải thiện đáng kể hiệu quả tương tác, nếu không đi kèm với nội dung chất lượng và yếu tố sáng tạo. Thay vì tập trung vào tần suất đăng bài, doanh nghiệp cần đầu tư vào những KOL có lịch sử nội dung tốt, biết cá nhân hóa thông điệp và có khả năng tạo ra các hình thức truyền tải mới mẻ.
- **Giả thuyết 5 và 6: Tác động của tần suất và thời điểm đăng bài PR đến hiệu quả tương tác vượt trội** Hai giả thuyết này kiểm định xem các yếu tố liên quan đến hoạt động đăng bài PR – bao gồm tổng số bài PR (`total_post_pr`) và thời điểm đăng vào cuối tuần (`is_weekend_pr`) – có ảnh hưởng đến số lượng bài PR đạt tỷ lệ tương tác vượt trội (`e_outlier_pr`) hay không. Ở giả thuyết 5, kết quả kiểm định Mann-Whitney U cho thấy  $p\text{-value} = 0.0141$  (nhỏ hơn 0.05), cho phép bác bỏ  $H_0$  và xác nhận rằng có sự khác biệt thống kê giữa nhóm KOL có tổng số bài PR  $> 100$  và nhóm còn lại. Hiệu ứng đạt mức trung bình ( $R = 0.36$ ), cho thấy việc đăng nhiều

bài PR có thể góp phần tích cực vào việc tạo ra nhiều bài PR thành công. Điều này phản ánh rằng những KOL có kinh nghiệm "ra trận" nhiều lần thường có khả năng duy trì hiệu suất tương tác ổn định hơn – một yếu tố quan trọng cho các chiến dịch truyền thông dài hạn. Trong khi đó, giả thuyết 6 tập trung vào yếu tố thời điểm – cụ thể là việc đăng bài vào cuối tuần. Kiểm định Kruskal-Wallis cho thấy sự khác biệt có ý nghĩa thống kê giữa ba nhóm KOL chia theo số lượng bài PR vào cuối tuần ( $p\text{-value} = 0.0028$ ), với hiệu ứng rất mạnh giữa nhóm high ( $>15$  bài) và nhóm low (0 bài), đạt  $R = 0.79$ . Điều này chứng minh rằng việc tập trung đăng bài vào cuối tuần – thời điểm người dùng có xu hướng online nhiều hơn – giúp tăng đáng kể số bài PR đạt hiệu quả vượt trội. Từ hai giả thuyết trên, có thể rút ra thông điệp chiến lược cho doanh nghiệp: thay vì chỉ đánh giá KOL dựa trên quy mô người theo dõi (follower), nên cân nhắc cả hai yếu tố thực chiến: (1) kinh nghiệm dày dặn trong việc đăng PR và (2) khả năng tận dụng thời điểm đăng bài thông minh – đặc biệt là vào cuối tuần. Tuy nhiên, cả hai yếu tố này chỉ phát huy tối đa khi đi cùng với chất lượng nội dung. Do đó, chiến thuật tần suất và thời điểm cần được kết hợp chặt chẽ với chiến lược nội dung để tối ưu hoá hiệu quả truyền thông toàn diện.

- **Giả thuyết 7 : Kiểm tra xem liệu tổng số caption của các bài PR có nội dung trending is\_trending\_pr có ảnh hưởng đến lượng follower mới (biến follower\_change\_in\_input\_window hay không** Giả thuyết  $H_0$  cho rằng không có sự khác biệt có ý nghĩa thống kê về mức tăng follower giữa nhóm có nhiều bài PR trending ( $\geq 20$ ) và nhóm có ít bài PR trending ( $< 20$ ). Kiểm định Mann-Whitney U được áp dụng do dữ liệu không tuân theo phân phối chuẩn và phương sai giữa hai nhóm không đồng đều. Kết quả kiểm định cho thấy  $p\text{-value} = 0.0395$ , nhỏ hơn ngưỡng ý nghĩa 0.05, cho phép bác bỏ giả thuyết  $H_0$  và kết luận rằng có sự khác biệt thống kê giữa hai nhóm. Tuy nhiên, hiệu ứng ở mức nhỏ ( $R = 0.26$ ), cho thấy mức độ tác động là hạn chế. việc đăng nhiều bài PR có nội dung trending không thực sự mang lại sự tăng trưởng follower đáng kể. Dù về mặt thống kê có sự khác biệt, nhưng giá trị thực tiễn lại mờ nhạt. Điều này gợi ý rằng nội dung trending không nên được xem là yếu tố cốt lõi nếu mục tiêu là tăng lượng người theo dõi. Các KOL và nhãn hàng nên cân nhắc tập trung vào những yếu tố có tác động rõ rệt hơn — chẳng hạn như chất lượng caption (ngắn gọn, gây tò mò, CTA mạnh), tính nhất quán trong phong cách nội dung, hoặc hiệu quả từ các series PR mang tính cá nhân hoá. Việc chạy theo xu hướng có thể thu hút sự chú ý ngắn hạn, nhưng không đảm bảo chuyển đổi thành hành vi theo dõi hoặc trung thành lâu dài từ người dùng.

### 3.5 Machine Learning Methodology

Phần này trình bày chi tiết về quy trình xây dựng và đánh giá các mô hình học máy được triển khai trong nghiên cứu. Chúng tôi tập trung vào việc mô tả cấu trúc dữ liệu đầu vào, chiến lược chia tập dữ liệu, các mô hình hồi quy được lựa

chọn, và các bước tiền xử lý dữ liệu cùng kỹ thuật diễn giải mô hình được áp dụng.

**Data Preparation and Splitting Strategy** Tất cả các mô hình học máy trong nghiên cứu này đều được huấn luyện và đánh giá trên tập dữ liệu được xây dựng ở cấp độ Level 2, nơi mỗi đơn vị mẫu (sample) tương ứng với một KOL trong một khung thời gian cụ thể, tổ chức theo chiến lược khung thời gian trượt (sliding window). Điều này cho phép mỗi KOL có thể đóng góp nhiều mẫu vào tập dữ liệu, phản ánh các giai đoạn hoạt động khác nhau của họ. Mặc dù các mẫu từ cùng một KOL có thể có phần thời gian chồng lấn trong giai đoạn đầu vào (input window) do chiến lược trượt, chúng tôi đảm bảo rằng không có sự trùng lặp thời gian nào giữa giai đoạn đầu vào của các mẫu huấn luyện/phát triển và giai đoạn đầu ra (output window) của tập kiểm tra. Điều này nhằm ngăn chặn rò rỉ thông tin (data leakage) và đảm bảo tính tin cậy của quá trình đánh giá mô hình, mô phỏng đúng điều kiện dự đoán "tương lai chưa biết". Chiến lược chia dữ liệu được thiết kế đặc biệt để bảo toàn tính độc lập theo thời gian và mô phỏng sát nhất ứng dụng thực tế:

- **Tập Kiểm tra (Test Set):** Bao gồm khung thời gian hoạt động gần nhất của mỗi KOL. Tập này được giữ lại hoàn toàn và không được sử dụng trong quá trình huấn luyện hay tinh chỉnh mô hình, đóng vai trò mô phỏng giai đoạn "tương lai chưa biết" mà mô hình sẽ phải đối mặt trong thực tế.
- **Tập Phát triển (Development Set - Dev Set):** Được chọn từ khung thời gian gần nhất còn lại sau khi đã tách tập kiểm tra. Tập này được sử dụng cho việc tinh chỉnh siêu tham số và lựa chọn mô hình.
- **Tập Huấn luyện (Train Set):** Bao gồm tất cả các khung thời gian trong quá khứ còn lại sau khi đã xác định tập kiểm tra và tập phát triển. Tập này được sử dụng để huấn luyện các mô hình.

Quy tắc chia này đảm bảo rằng các tháng trong giai đoạn đầu ra của tập kiểm tra sẽ không trùng với bất kỳ giai đoạn đầu vào hoặc đầu ra nào trong tập huấn luyện và tập phát triển, duy trì điều kiện đánh giá mô hình đúng nghĩa "future unseen".

**Model Selection** Nghiên cứu triển khai một bộ các thuật toán hồi quy đa dạng, được phân thành hai nhóm chính để khám phá các đặc điểm và hiệu suất khác nhau của dữ liệu:

- **Nhóm Mô hình Tuyến tính (Linear Models):** Đây là các mô hình cơ bản nhưng mạnh mẽ, cung cấp khả năng diễn giải tốt về mối quan hệ giữa các đặc trưng và biến mục tiêu. Các mô hình được lựa chọn bao gồm Linear Regression (hồi quy tuyến tính), Ridge Regression (hồi quy Ridge), Lasso Regression (hồi quy Lasso), và Support Vector Regression (SVR - hồi quy máy vector hỗ trợ).
- **Nhóm Mô hình Dựa trên Cây Quyết định (Tree-based Models):** Nhóm này bao gồm các thuật toán mạnh mẽ và linh hoạt, có khả năng

nắm bắt các mối quan hệ phi tuyến tính phức tạp trong dữ liệu. Các mô hình được sử dụng là Random Forest Regressor, Extra Trees Regressor, HistGradientBoosting Regressor, XGBoost, LightGBM và CatBoost.

**Data Preprocessing Pipelines** Để đảm bảo đầu vào tối ưu và phù hợp với đặc điểm của từng nhóm mô hình, quá trình tiền xử lý dữ liệu được thiết kế riêng biệt và áp dụng một cách linh hoạt:




Fig. 3: Phân phối tỷ lệ tương tác (output) trên bài đăng PR trong tập DEV & TRAIN

- **Chuyển đổi Biến Mục tiêu (Target Variable Transformation):** Để đối phó với hiện tượng phân phối lệch phải rõ rệt của biến mục tiêu (*EngagementRateOnPRPost\_target*), chúng tôi đã áp dụng phép biến đổi  $\log(1+x)$  ( $\log1p$ ) trước khi đưa dữ liệu vào huấn luyện mô hình. Phép biến đổi này giúp nén lại các giá trị ngoại lai lớn, đồng thời làm cho phân phối dữ liệu tiệm cận chuẩn hơn và giảm sai số do ảnh hưởng của đuôi phân phối dài. Ngoài ra, việc áp dụng  $\log1p$  còn giúp ổn định phương sai và cải thiện khả năng mô hình hóa tuyến tính giữa các đặc trưng đầu vào và đầu ra.
- **Tiền xử lý cho Mô hình Tuyến tính:** Đối với nhóm mô hình tuyến tính, toàn bộ đặc trưng đầu vào được chuẩn hóa bằng *StandardScaler*. Quá trình này giúp đưa các đặc trưng về phân phối chuẩn với trung bình bằng 0 và độ lệch chuẩn bằng 1. Việc chuẩn hóa là cần thiết để ngăn chặn các đặc trưng có thang đo lớn hơn (ví dụ: số lượng người theo dõi) áp đảo các đặc trưng có thang đo nhỏ hơn (ví dụ: số lượng emoji), từ đó cải thiện tốc độ hội tụ và độ ổn định của thuật toán tối ưu. Ngoài ra, để giảm thiểu hiện tượng đa cộng

tuyến (multicollinearity) – vốn gây nhiễu trong ước lượng tham số và làm giảm tính ổn định của mô hình tuyến tính – nghiên cứu áp dụng *Phân tích thành phần chính (Principal Component Analysis – PCA)* như một bước tiền xử lý bổ sung. PCA giúp xác định các trục phương sai chính trong dữ liệu và giảm số chiều mà vẫn giữ lại phần lớn thông tin quan trọng. Việc sử dụng PCA không chỉ cải thiện độ chính xác của các mô hình tuyến tính mà còn giảm nguy cơ quá khớp (overfitting) khi số lượng đặc trưng cao so với số mẫu.

- **Tiền xử lý cho Mô hình Dựa trên Cây Quyết định:** Nhóm mô hình cây quyết định, vốn có khả năng xử lý các đặc trưng với thang đo và phân phối khác nhau, không yêu cầu chuẩn hóa dữ liệu. Do đó chúng tôi áp dụng 3 phương pháp dưới đây để hiểu thêm về dữ liệu cũng như lựa chọn các đặc trưng ảnh hưởng mạnh vào target thay vì đưa toàn bộ vào để tránh nhiễu.

**Model Interpretability and Feature Importance Analysis** Để hiểu rõ hơn về vai trò và mức độ ảnh hưởng của từng đặc trưng đầu vào đến đầu ra dự đoán của mô hình, nghiên cứu triển khai ba kỹ thuật phân tích đặc trưng song song:




Fig. 4: Các kỹ thuật phân tích tầm quan trọng đặc trưng

- **Feature Importance (Nội tại từ Mô hình - LightGBM Gain):** Đây là phương pháp đơn giản và phổ biến, đo lường mức độ quan trọng của một đặc trưng dựa trên tần suất và hiệu quả của nó trong việc phân chia dữ liệu, thường thông qua mức giảm bất định (impurity reduction) hoặc mức giảm sai số. Từ biểu đồ "Top 20 Features theo Gain (LightGBM)" (fig. 4a), chúng ta thấy rõ rằng **pr\_engagement\_rate\_input** là đặc trưng quan trọng nhất với độ ảnh hưởng vượt trội, góp phần lớn nhất vào việc giảm lỗi của mô hình. Các đặc trưng như **shareCount\_pr**, **unique\_music\_nonpr** cũng cho thấy tầm quan trọng đáng kể, cho thấy mô hình học được rất nhiều từ

các chỉ số tương tác chính. Tuy nhiên, phương pháp này có thể bị thiên lệch đối với các đặc trưng có nhiều giá trị phân biệt (high cardinality).

- **Permutation Importance:** Kỹ thuật này đánh giá tầm quan trọng của từng đặc trưng bằng cách hoán vị (shuffle) ngẫu nhiên các giá trị của đặc trưng đó trên tập kiểm tra và quan sát mức suy giảm hiệu suất của mô hình. Nếu hiệu suất mô hình giảm đáng kể sau khi hoán vị, đặc trưng đó được xem là quan trọng. Ưu điểm nổi bật của Permutation Importance là tính độc lập với cấu trúc nội tại của mô hình, phản ánh ảnh hưởng thực nghiệm của đặc trưng đến dự đoán. Biểu đồ "Top 20 Features theo Permutation Importance" (**fig. 4b**) củng cố mạnh mẽ nhận định về `pr_engagement_rate_input` là đặc trưng có ảnh hưởng lớn nhất, khi việc xáo trộn giá trị của nó làm suy giảm hiệu suất mô hình (được đo bằng  $\Delta RMSE$ ) đáng kể nhất. Sự tương đồng về thứ hạng của các đặc trưng hàng đầu (như `unique_music_nonpr`, `shareCount_nonpr`, `isSlideshow_nonpr`) giữa Permutation Importance và LightGBM Gain cho thấy sự nhất quán và đáng tin cậy về tầm quan trọng thực sự của các đặc trưng này đối với khả năng dự đoán của mô hình.
- **SHAP (SHapley Additive Explanations):** SHAP là một phương pháp dựa trên lý thuyết trò chơi hợp tác, cho phép tính toán đóng góp cận biên của từng đặc trưng cho mỗi dự đoán cá nhân. Khác với hai phương pháp trên thiên về phân tích tầm quan trọng tổng thể (global interpretability), SHAP cung cấp khả năng phân tích cụ thể từng dự đoán đầu ra (local interpretability), giúp diễn giải chi tiết vì sao mô hình đưa ra một dự đoán nhất định cho một trường hợp cụ thể (ví dụ: vì sao một KOL có hiệu suất cao hoặc thấp). Biểu đồ "SHAP value" (**fig. 4c**) minh họa rõ ràng cách mỗi đặc trưng ảnh hưởng đến từng dự đoán riêng lẻ. Đặc biệt, `pr_engagement_rate_input` thể hiện sự phân tán SHAP value rộng nhất, cho thấy nó có khả năng đẩy kết quả dự đoán lên cao (điểm màu đỏ sang phải) hoặc kéo xuống thấp (điểm màu xanh sang trái) tùy thuộc vào giá trị của nó. Chúng ta cũng có thể quan sát xu hướng: ví dụ, các giá trị cao hơn của `unique_music_nonpr` (màu đỏ) thường có SHAP value dương, cho thấy nhạc độc đáo có xu hướng đóng góp tích cực vào hiệu suất. Ngược lại, đối với `isSlideshow_nonpr`, các giá trị cao hơn (màu đỏ) lại có xu hướng SHAP value âm, gợi ý rằng định dạng slideshow có thể không luôn mang lại hiệu quả tốt trong ngữ cảnh này. Đây là một công cụ cực kỳ hữu ích trong các ứng dụng thực tế, nơi nhà tiếp thị cần lời giải thích cụ thể cho từng trường hợp để đưa ra quyết định tối ưu.

Việc sử dụng phối hợp cả ba kỹ thuật này giúp cân bằng giữa hiểu biết toàn cục (global interpretability) và hiểu biết cục bộ (local interpretability) của mô hình, đồng thời cho phép chúng ta không chỉ xác định được các đặc trưng quan trọng nhất (`pr_engagement_rate_input`, `unique_music_nonpr`, `shareCount_pr`) mà còn hiểu được cách chúng tác động đến đầu ra và mức độ ổn định của tầm quan trọng đó qua các phương pháp đánh giá khác nhau. Sự kết hợp giữa các phân tích tầm quan trọng của đặc trưng này với phần Hypothesis Testing đã hỗ trợ hiệu quả trong việc lựa chọn ra Top 20/64 thuộc tính ban đầu để huấn luyện mô hình, từ đó tối ưu hóa mô hình và chiến lược tiếp thị. Sau khi xây dựng xong pipeline mô hình và áp dụng các bước xử lý tương ứng, toàn bộ mô hình được

đánh giá đồng nhất trên tập phát triển và tập kiểm tra theo các chỉ số sẽ trình bày chi tiết ở phần tiếp theo.

## 4 Results

Phần này trình bày kết quả đánh giá hiệu suất của các mô hình học máy đã được huấn luyện. Chúng tôi so sánh các mô hình dựa trên các chỉ số hiệu suất chính trên tập kiểm tra.

Table 2: Kết quả Đánh giá Hiệu suất của các Mô hình Hồi quy

| Models                           | MAE    | MAE / Mean Target | R <sup>2</sup> |
|----------------------------------|--------|-------------------|----------------|
| Linear Regression                | 0.0179 | 71.39%            | -0.1060        |
| Ridge Regression                 | 0.0173 | 68.79%            | -0.0312        |
| Support Vector Regression        | 0.0250 | 99.77%            | -0.0295        |
| Random Forest                    | 0.0156 | 62.37%            | -0.0445        |
| Extra Trees Regressor            | 0.0154 | 61.23%            | -0.0218        |
| Hist Gradient Boosting Regressor | 0.0162 | 64.49%            | -0.0422        |
| XGBoost                          | 0.0167 | 66.78%            | -0.0251        |
| LightGBM                         | 0.0164 | 65.46%            | -0.0504        |
| CatBoost                         | 0.0153 | 61.07%            | -0.0258        |

Để đánh giá hiệu suất của các mô hình hồi quy, nghiên cứu sử dụng ba chỉ số chính: Sai số tuyệt đối trung bình (Mean Absolute Error - MAE), Tỷ lệ phần trăm sai số tuyệt đối trung bình trên giá trị trung bình của biến mục tiêu (MAE / Mean Target), và Hệ số xác định (Coefficient of Determination - R<sup>2</sup>).

- **Mean Absolute Error (MAE):** MAE đo lường giá trị trung bình của sự khác biệt tuyệt đối giữa các giá trị dự đoán và giá trị thực tế của biến mục tiêu. Giá trị MAE càng nhỏ cho thấy mô hình dự đoán càng chính xác. Công thức của MAE được định nghĩa là:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **MAE / Mean Target:** Chỉ số này biểu thị tỷ lệ phần trăm sai số tuyệt đối trung bình so với giá trị trung bình của biến mục tiêu. Nó cung cấp một cái nhìn chuẩn hóa về độ chính xác của mô hình so với thang đo của biến mục tiêu, giúp đánh giá hiệu quả ngay cả khi biến mục tiêu có biên độ giá trị rộng. Tỷ lệ này càng thấp càng tốt. Công thức của MAE / Mean Target là:

$$\text{MAE / Mean Target} = \frac{\text{MAE}}{\text{Mean}(y)} \times 100\%$$



- **$R^2$  (Coefficient of Determination)**:  $R^2$  đo lường mức độ mà các biến đầu vào của mô hình giải thích được sự biến thiên của biến mục tiêu. Giá trị  $R^2$  càng gần 1 cho thấy mô hình giải thích được nhiều sự biến thiên và có khả năng dự đoán tốt. Công thức của  $R^2$  là:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Trong đó, giá trị  $R^2$  âm (như một số mô hình trong bảng kết quả) chỉ ra rằng mô hình hoạt động kém hơn so với việc chỉ dự đoán giá trị trung bình của biến mục tiêu, thường là dấu hiệu của việc mô hình không nắm bắt được mối quan hệ trong dữ liệu chưa thấy hoặc bị quá khớp trên tập huấn luyện.

Việc sử dụng kết hợp các chỉ số này giúp cung cấp một cái nhìn toàn diện về hiệu suất của mô hình.

## 5 Discussion

Kết quả đánh giá hiệu suất của các mô hình hồi quy cho thấy thách thức đáng kể trong việc đạt được khả năng dự đoán chính xác. Cụ thể, tất cả các mô hình được thử nghiệm đều cho giá trị  $R^2$  âm, điều này chỉ ra rằng chúng hoạt động kém hơn cả một mô hình nền đơn giản (dự đoán bằng giá trị trung bình của biến mục tiêu) trên tập kiểm tra. Mặc dù Sai số tuyệt đối trung bình (MAE) của các mô hình dao động trong khoảng 0.015 đến 0.025, tương ứng với 61% đến 99% giá trị trung bình của biến mục tiêu (khoảng 0.017), điều này phản ánh rằng ngay cả sai số tuyệt đối nhỏ cũng trở nên đáng kể khi so sánh với biên độ giá trị của biến mục tiêu. Những phát hiện này gợi ý rằng mô hình chưa thực sự nắm bắt được các quy luật phức tạp hoặc mối quan hệ phi tuyến tính tiềm ẩn trong dữ liệu.

Trong số các thuật toán được đánh giá, Extra Trees Regressor và CatBoost cho thấy hiệu suất tương đối tốt nhất, với MAE thấp nhất (0.0154 và 0.0153 tương ứng) và giá trị  $R^2$  gần bằng 0 (-0.0218 và -0.0258 tương ứng). Mặc dù chưa đạt được độ chính xác lý tưởng, kết quả này cho thấy tiềm năng của các mô hình dựa trên cây tăng cường (ensemble tree-based models) trong việc xử lý các tập dữ liệu có phân phối phức tạp và mối quan hệ phi tuyến tính.

Có một số nguyên nhân chính có thể lý giải cho hiệu suất chưa tối ưu của các mô hình. Thứ nhất, **quy mô và độ bao phủ dữ liệu hạn chế** (tập huấn luyện 267 mẫu, kiểm tra 69 mẫu) đã gây khó khăn cho mô hình trong việc học các mối quan hệ phức tạp và tổng quát hóa trên dữ liệu mới. Thêm vào đó, việc dữ liệu chỉ tập trung trong lĩnh vực mỹ phẩm cũng làm giảm tính tổng quát của mô hình. Thứ hai, **đặc điểm phân phối lệch của biến mục tiêu** (tỷ lệ tương tác trung bình trên mỗi lượt xem của các bài đăng PR) vẫn còn rõ rệt ngay cả sau khi áp dụng phép biến đổi  $\log(1+x)$ , điều này có thể gây khó khăn cho các thuật toán hồi quy trong việc học đúng xu hướng. Thứ ba, **bộ đặc trưng đầu vào hiện tại có thể chưa đủ giàu thông tin** để phân biệt hiệu quả giữa các KOL. Nhiều đặc trưng được xây dựng dựa trên dữ liệu định lượng đơn

thuần (như số lượng tương tác, loại bài đăng, thời điểm đăng), trong khi hiệu quả tương tác trên TikTok còn phụ thuộc đáng kể vào các yếu tố định tính và ngữ cảnh như nội dung video, cảm xúc người xem, xu hướng mạng xã hội, và phong cách thể hiện của KOL. Cuối cùng, **thách thức trong quy trình đánh giá mô hình** do đặc thù chuỗi thời gian của dữ liệu (thiết kế khung thời gian trượt) đã hạn chế việc áp dụng kiểm định chéo truyền thống, ảnh hưởng đến tính khách quan của kết luận về hiệu suất.

Những phân tích này cung cấp cơ sở để định hướng các cải tiến trong nghiên cứu tương lai nhằm nâng cao hiệu suất dự đoán của mô hình.

## 6 Limitations and Future Work

Phần này trình bày những giới hạn của nghiên cứu hiện tại và đề xuất các hướng phát triển tiềm năng nhằm khắc phục các hạn chế đó, từ đó nâng cao chất lượng và khả năng ứng dụng của mô hình trong tương lai.

### 6.1 Limitations

- **Quy mô và Phạm vi Dữ liệu Hạn chế:** Nghiên cứu này hiện dựa trên một tập dữ liệu chuyên biệt, rất ít mẫu với data level 2 và chỉ tập trung vào các KOL trong ngành mỹ phẩm. Hạn chế về ngân sách và tài nguyên đã gây khó khăn trong việc thu thập một tập dữ liệu phong phú và đa dạng hơn, vốn có thể cung cấp những insight sâu sắc hơn.
- **Thiên kiến trong quá trình xác định ngưỡng phân nhóm Giả Thuyết:** Các ngưỡng chỉ số dùng để phân nhóm được xác định hoàn toàn thủ công, dựa trên quan sát chủ quan và kinh nghiệm cá nhân của người thực hiện. Việc này tiềm ẩn nguy cơ thiên kiến, ảnh hưởng đến tính khách quan và khả năng tổng quát hóa của mô hình.
- **Chưa Khai thác Toàn diện Dữ liệu Đa phương tiện:** Nghiên cứu hiện tại chưa tích hợp các đặc trưng từ yếu tố đa phương tiện vốn đặc trưng cho TikTok, bao gồm nội dung video, âm thanh và hiệu ứng hình ảnh. Đây là một hạn chế vì các yếu tố này đóng vai trò quan trọng trong việc tạo ra sức hút và tương tác do thiếu hụt tài nguyên máy tính cần thiết cho quá trình xử lý và mô hình hóa.
- **Chất lượng của Đặc trưng Phái sinh từ LLM:** Một số đặc trưng kỹ thuật, như *is\_trending*, được tạo ra thông qua các mô hình ngôn ngữ lớn (LLM). Tuy nhiên, phiên bản LLM được sử dụng trong nghiên cứu này còn mang tính thử nghiệm và chưa đạt được độ tin cậy tối ưu trong việc gán nhãn ngữ nghĩa.
- **Giới hạn về Chỉ số Kết quả Cuối cùng:** Nghiên cứu chưa thể tiếp cận các dữ liệu độc quyền và có giá trị cao từ các chiến dịch KOL, ví dụ như số lượt click thực tế, doanh thu trực tiếp, hoặc thông tin phản hồi từ nhân hàng. Việc thiếu các chỉ số "kết quả cuối cùng" này khiến mô hình phải dựa vào các tín hiệu tương tác gián tiếp, vốn có thể chứa nhiễu.

- **Thách thức trong Đánh giá Mô hình Thời gian:** Do đặc thù của thiết kế dữ liệu theo dạng khung thời gian trượt, việc áp dụng kiểm định chéo truyền thống là không khả thi. Điều này dẫn đến việc mô hình chỉ được đánh giá dựa trên một phân tách thời gian cố định, làm giảm tính khách quan và độ tin cậy trong kết luận về hiệu suất tổng thể của mô hình.

## 6.2 Future Work

Để khắc phục các giới hạn nêu trên và nâng cao chất lượng mô hình trong tương lai, nghiên cứu đề xuất một số định hướng phát triển chính:

- **Mở rộng Quy mô và Đa dạng hóa Dữ liệu:** Cần tìm kiếm nguồn tài trợ từ doanh nghiệp hoặc tổ chức nghiên cứu để mở rộng quy mô bộ dữ liệu và đa dạng hóa nguồn thu thập. Điều này sẽ cho phép bao phủ nhiều lĩnh vực nội dung hơn (ví dụ: thời trang, thực phẩm, chăm sóc sức khỏe), từ đó tăng tính tổng quát và khả năng ứng dụng của mô hình.
- **Áp dụng các phương pháp xác định ngưỡng tự động:** Trong các nghiên cứu tiếp theo, việc xác định các ngưỡng phân nhóm sẽ được thực hiện bằng các phương pháp có tính hệ thống và khách quan hơn. Cụ thể, áp dụng các kỹ thuật tối ưu hoá tham số, phân cụm (clustering), hoặc các thuật toán học có giám sát/không giám sát để tìm ra các ngưỡng phù hợp dựa trên dữ liệu thực tế, thay vì dựa trên cảm quan chủ quan. Việc này không chỉ giúp giảm thiểu thiên kiến cá nhân mà còn nâng cao tính tái lập và độ chính xác của mô hình giả thuyết.
- **Tích hợp Đặc trưng Đa phương tiện Tiên tiến:** Phát triển các phương pháp để trích xuất và tích hợp đặc trưng từ nội dung đa phương tiện của TikTok, bao gồm các embedding từ video (ví dụ: visual embeddings, frame dynamics), âm thanh (mel-spectrogram, phân loại nhạc nền), và hình ảnh (biểu cảm khuôn mặt, ánh sáng, màu sắc). Việc này sẽ giúp mô hình hiểu sâu hơn về thông điệp và phong cách truyền tải của từng KOL.
- **Nâng cao Chất lượng Đặc trưng từ LLM:** Ứng dụng các mô hình ngôn ngữ lớn tiên tiến hơn (ví dụ: các SOTA LLMs như GPT-4 hoặc Claude) để tạo ra các đặc trưng ngữ nghĩa với độ chính xác và độ tin cậy cao hơn. Đồng thời, cần tiến hành kiểm định độ ổn định và độ đồng thuận của các đặc trưng này trước khi đưa vào mô hình.
- **Áp dụng Mô hình Học Liên tục (Online Learning):** Triển khai các phương pháp học liên tục để cập nhật mô hình theo thời gian thực mỗi khi có dữ liệu mới về hành vi KOL hoặc xu hướng thị trường. Điều này đặc biệt phù hợp trong bối cảnh nội dung trên TikTok thay đổi nhanh chóng và liên tục, giúp mô hình duy trì độ chính xác và tính phù hợp.
- **Thiết kế Quy trình Đánh giá Mô hình Chuỗi thời gian Chuyên biệt:** Phát triển và áp dụng các phương pháp đánh giá mô hình phù hợp hơn với dữ liệu dạng chuỗi thời gian, như kiểm định chéo theo chuỗi thời gian (time-series cross-validation), rolling validation, hoặc expanding window validation. Các phương pháp này sẽ giúp đánh giá hiệu suất mô hình một cách thực tế và đáng tin cậy hơn trong các ứng dụng triển khai thực tế.

## 7 Conclusion

Nghiên cứu này đã đề xuất một phương pháp định lượng toàn diện và có hệ thống nhằm dự đoán hiệu quả tương tác của các Nhà sáng tạo nội dung chính (KOLs) trên nền tảng TikTok. Chúng tôi đã xây dựng một bộ dữ liệu độc đáo ở cấp độ KOL theo chiến lược khung thời gian trượt và thử nghiệm một loạt các mô hình hồi quy thuộc nhóm tuyến tính và cây quyết định. Mặc dù các mô hình hiện tại vẫn còn những hạn chế nhất định khi tất cả đều cho giá trị  $R^2$  âm trên tập kiểm tra, kết quả thực nghiệm đã chỉ ra Extra Trees Regressor và CatBoost là hai thuật toán có hiệu suất tốt nhất với MAE thấp nhất.

Chúng tôi cũng đã tiến hành phân tích sâu rộng về các yếu tố có thể ảnh hưởng đến hiệu suất của mô hình, bao gồm quy mô và phạm vi dữ liệu hạn chế, việc chưa khai thác toàn diện dữ liệu đa phương tiện, chất lượng của các đặc trưng phái sinh từ LLM, và giới hạn trong việc tiếp cận các chỉ số kết quả cuối cùng. Những phân tích này không chỉ cung cấp cái nhìn sâu sắc về thách thức trong việc dự đoán hiệu suất KOL mà còn đặt nền móng vững chắc cho các nghiên cứu tiếp theo. Trong tương lai, chúng tôi sẽ tập trung vào việc mở rộng quy mô và đa dạng hóa bộ dữ liệu, tích hợp các đặc trưng đa phương tiện và ngữ nghĩa tiên tiến, cũng như khám phá các phương pháp đánh giá mô hình phù hợp hơn cho dữ liệu chuỗi thời gian, với mục tiêu nâng cao đáng kể độ chính xác và khả năng ứng dụng thực tiễn của hệ thống dự đoán.

## References

1. Exolyt. TikTok Analytics Tool. Available at: <https://exolyt.com/>.
2. Social Blade: Real-time statistics and analytics for YouTube, TikTok, Instagram and more. <https://socialblade.com/> (2024)
3. Apify: TikTok Scraper by Clockworks – Extract user videos, stats and profile info. <https://apify.com/clockworks/tiktok-scraper> (2024)
4. MediaLabs Asia: Top 10 KOL mỹ phẩm uy tín tại Việt Nam và bí quyết hợp tác hiệu quả. <https://medialabs.asia/our-update/brand-marketing/top-10-kol-my-pham-uy-tin-tai-viet-nam-va-183> (2024)
5. An, R., Shi, X., Xu, B.: Fast automatic feature selection for multi-period sliding window aggregate in time series. arXiv preprint arXiv:2012.01037 (2020)
6. Revu Vietnam: Danh sách KOL mỹ phẩm (beauty influencer) nổi bật tại Việt Nam. <https://blog.vn.revu.net/danh-sach-kol-my-pham-beauty-influencer/> (2023)
7. Yin, Z., et al.: Evaluating the effectiveness of a sliding window technique in machine learning models for mortality prediction in ICU. *BMC Medical Informatics and Decision Making* **24**(1), 1–14 (2024)
8. Jeyalakshmi, R., Umamathy, S.: Versatile time-window sliding machine learning techniques for stock market forecasting. *Artificial Intelligence Review* **57**(3), 2801–2829 (2024)
9. Al-Kahtani, N.S., Alshahrani, S., Abualigah, L.: Explainable Artificial Intelligence (XAI): A comprehensive review. *Journal of Artificial Intelligence* **13**(4), 196–216 (2023)
10. Influencer Marketing Hub: Influencer Marketing Benchmark Report 2024. <https://influencermarketinghub.com/influencer-marketing-benchmark-report/> (2024)

11. Zhao, Q., Yang, Y.: An empirical survey on explainable AI technologies. *\*Electronics\** **12**(5), 1092 (2023)
12. Hooker, G., Mentch, L.: Unrestricted permutation forces extrapolation: Variable importance requires at least one more model. *\*Statistics and Computing\** **31**(3), 1–14 (2021)
13. Dao, C.T., Nguyen, N.Q., Le, T.H., Nguyen, T.M.P.: The moderating effects of involvement on the relationships between key opinion leaders, customer's attitude and purchase intention on social media. *\*Cogent Business & Management\** **11**(1), 2400600 (2024)
14. Tran, T.Q.G., Ho, T.H.H.: Researching the impact of TikTok influencers on students' purchase intention. *\*Hue University Journal of Science: Economics and Development\** **132**(4A), 45–58 (2025)
15. Planket, A., et al.: How KOLs influence consumer purchase intention in short video platforms: Mediating effects of emotional response and virtual touch. *\*ResearchGate Preprint\**. <https://www.researchgate.net/publication/363270392> (2024)
16. de la Calle, G., Sanz-Medel, A., & Encinar, J. R. (2017). Resolution of Student's t-tests, ANOVA and analysis of variance components from intermediary data. *Accreditation and Quality Assurance*, *22*(5), 241–251. <https://doi.org/10.1007/s00769-017-1293-4>
17. Cui, J. (2025). A comparative analysis of statistical methods in social science research: ANOVA, multi-factor ANOVA, chi-square, and t-test. *Social Science Research Archive*. <https://www.researchgate.net/publication/39035355>
18. Gosset, W. S. (1908). The probable error of a mean. *Biometrika*, *6*(1), 1–25.
19. Fisher, R. A. (1925). *Statistical methods for research workers* (1st ed.). Oliver and Boyd.
20. Thompson, H. W., Mera, R., & Prasad, C. (1998). A description of the appropriate use of Student's t-test. *Nutrition Neuroscience*, *1*(2), 165–172. <https://doi.org/10.1080/1028415X.1998.11747213>